

1. El aprendizaje profundo (marca todas las respuestas correctas):

- A. Es una técnica dentro del aprendizaje automático.
- B. Es un área de la inteligencia artificial.
- C. Está basado en reglas formales diseñadas por humanos.
- D. Depende de bases de conocimiento diseñadas por humanos.
- E. Se basa en entender conceptos cada vez más complejos.

2. ¿Qué factores pueden explicar el concepto «profundo» en el término de aprendizaje profundo? (Marca todas las respuestas correctas):

- A. Los algoritmos de aprendizaje profundo aprenden con una profundidad nunca vista hasta ahora.
- B. Las redes neuronales se hacen profundas con la introducción de múltiples capas.
- C. Las redes neuronales pueden aprender jerarquías complejas de conceptos.
- D. Los problemas resueltos por el aprendizaje profundo son más complejos y complicados para el hombre.
- E. El deep learning es capaz de realizar razonamientos como una persona.

3. En un problema de clasificación de personas a partir de imágenes con aprendizaje profundo, ¿cuál es la entrada que recibiría la red neuronal?

- A. Una serie de features diseñadas por humanos en la imagen. Por ejemplo, color de cabello, uso de gafas o no, color de ojos, color de piel...
- B. Una representación de la imagen dada por otros algoritmos.
- C. Los píxeles de la imagen.

4. El deep learning (marca la respuesta correcta):

- A. Ha tenido varios nombres a lo largo de la historia.
- B. Consiste en una serie de técnicas y avances muy recientes.
- C. Ha tenido siempre una posición predominante en el mundo de la inteligencia artificial.
- D. Es, tras todos sus avances, la mejor solución para todos los problemas de aprendizaje automático.

5. ¿Qué cantidad de datos es necesaria para entrenar con éxito una red neuronal profunda?

- A. Entre 100 y 1000 training examples.
- B. Entre 1000 y 100 000 training examples.
- C. Más de 100 000 training examples.
- D. La cantidad depende del problema a tratar.

6. ¿Cuáles son algunas de las aplicaciones del deep learning? (Marca todas las respuestas correctas):

- A. Visión por computador.
- B. Traducción automática.
- C. Agentes que aprenden a jugar a juegos.
- D. Reconocer el habla.

7. Señala la afirmación correcta:

- A. Una red neuronal es un cerebro artificial.
- B. El aprendizaje profundo está inspirado en el funcionamiento del cerebro, pero las similitudes entre los algoritmos de deep learning y el cerebro acaban pronto.
- C. El aprendizaje profundo está inspirado en el funcionamiento del cerebro y cada nuevo avance en el área lo acerca más a este.

8. En una red neuronal, si una neurona tiene 5 inputs, ¿cuántos parámetros la modelan?

- A. 5
- B. 6
- C. 7
- D. 10
- E. 11
- F. 12

9. En una red neuronal fully connected con una input layer con 10 nodos, una hidden layer con 5 nodos y una output layer con 10 nodos, ¿cuántos parámetros tiene en total la red neuronal?

- A. 25
- B. 110
- C. 115
- D. 125
- E. 220

10. Marca todas las respuestas correctas acerca del funcionamiento de una red neuronal:

- A. La salida de una neurona es una representación de una probabilidad.
- B. La input layer es una representación de los datos de entrada y no conlleva cálculos.
- C. Las neuronas se activan con un valor definido por la función de activación.
- D. En una feed-forward network, la información siempre fluye hacia delante.

11. Marca las respuestas verdaderas sobre el algoritmo stochastic gradient descent:

- A. En SGD obtenemos una estimación del gradiente. Si bien el gradiente no es exacto, la dirección de este es más o menos correcta, de modo que el proceso de minimización todavía funciona.
- B. El tamaño de la batch m cuanto más pequeño, mejor para acelerar el entrenamiento. De hecho es buena idea usar valores de m como 1, 2 o 3.
- C. La elección de m afecta a la velocidad de entrenamiento de nuestra red neuronal.
- D. Hay que elegir m con un balance, de modo que la aproximación al gradiente sea buena, pero no necesitemos utilizar una gran cantidad de puntos del dataset.

12. Seleccionar un motivo por el que en SGD utilizamos batches aleatorias hasta agotar todos los training examples del dataset (completar una epoch), en vez de utilizar siempre elementos al azar:

- A. Programar una lógica de muestreo con reemplazamiento es más difícil y computacionalmente costoso.
- B. Una estimación utilizando elementos siempre al azar es una estimación incorrecta y la red neuronal nunca llegaría a aprender nada.
- C. Todos los training examples del dataset son importantes y poseen una variabilidad que la red neuronal tiene que saber explicar. Al forzar a la red a entrenar con todos ellos, permitimos que todos estos datos sean tomados en cuenta.

13. Para aplicar gradient descent, la función de coste tiene que ser (marca la respuesta correcta):

- A. Diferenciable.
- B. Integrable.
- C. Contener cuadrados de valores.
- D. Convexa.

14. Si aplicamos un valor demasiado grande de learning rate (marca la respuesta correcta):

- A. La red neuronal aprendería y lo haría de manera más rápida.
- B. La red neuronal aprendería igualmente, el efecto de la learning rate no es realmente importante.
- C. La red neuronal podría no aprender, ya que SGD acabaría convergiendo en un máximo en vez de en un mínimo.
- D. La red neuronal podría no aprender. La aproximación local de la derivada deja de tener efecto y podríamos overshoot a un punto lejano donde el valor de la función es de hecho mayor.

15. Si un dataset tiene 10 000 puntos y utilizamos batches de 10 examples para entrenar una red neuronal (marca la respuesta correcta):

- A. Una epoch o época de entrenamiento consiste en 10 steps.
- B. Una epoch o época de entrenamiento consiste en 100 steps.
- C. Una epoch o época de entrenamiento consiste en 1000 steps.
- D. Una epoch o época de entrenamiento consiste en 10 000 steps.
- E. Ninguna de las anteriores.

16. Las funciones de coste o loss functions (marca todas las respuestas correctas):

- A. Definen un valor de error que queremos minimizar.
- B. Definen un valor de coste que queremos maximizar.
- C. Son siempre variaciones de la función mean squared error.
- D. Implican un objetivo distinto a la hora de entrenar una red neuronal y, por tanto, son una parte importante a definir en un problema de machine learning.
- E. Son poco importantes a la hora de entrenar.

17. Durante el algoritmo de backpropagation (marca la respuesta correcta):

- A. No es necesario almacenar los valores de salida de cada nodo, solo nos interesa el valor final de la función de coste tras ejecutar el forward pass.
- B. Guardamos los valores de salida de cada nodo, ya que son necesarios para el cálculo de gradientes durante el backward pass.
- C. Guardamos los valores de salida de cada nodo, ya que son necesarios para aplicar gradient descent, pero no son usados en el cálculo de gradientes.
- D. Ninguna de las anteriores.

18. Marca todas las respuestas correctas acerca del algoritmo de backpropagation:

- A. Es una forma eficiente de calcular los gradientes necesarios para redes neuronales arbitrariamente complejas.
- B. Se llama backpropagation ya que el gradiente se propaga de manera recursiva hacia atrás.
- C. Fue un gran avance, ya que calcular fórmulas de los gradientes analíticamente se vuelve muy complejo para las redes neuronales.

19. En una operación suma $q=x+y+z$, si el gradiente propagado de salida es 5 (marca la respuesta correcta):

- A. El gradiente es 15 en todas las variables.
- B. El gradiente es 1 en todas las variables.
- C. El gradiente es 5 en todas las variables.
- D. No es posible saber el valor del gradiente con la información suministrada.

20. El número de neuronas a utilizar en las hidden layer (marca las respuestas correctas):

- A. Suele estar comprendido entre 10 y 100 neuronas. Menos es insuficiente y más es superfluo.
- B. Puede ser obtenido mediante una búsqueda de hiperparámetros.
- C. A más neuronas, más gradientes a calcular y, por tanto, más requisitos de memoria y tiempo de ejecución.
- D. No es muy importante a la hora de entrenar una red neuronal.
- E. A más neuronas, más capacidad de representación que tiene la red.

21. Los grafos de computación (marca todas las respuestas correctas):

- A. Facilitan el cálculo de derivadas automáticas.
- B. Facilitan la ejecución de subtarefas en entornos distribuidos.
- C. Implican normalmente menor velocidad de ejecución ya que tienen que ser definidos de antemano.

22. En el siguiente código, add_op es:

```
x = 2
```

```
y = 3
```

```
add_op = tf.add(x, y)
```

```
mul_op = tf.multiply(x, y)
```

```
mul_op_2 = tf.multiply(x, add_op)
```

```
pow_op = tf.pow(add_op, mul_op)
```

```
with tf.Session() as sess:
```

```
    z = sess.run(pow_op)
```

- A. 5.
- B. Un tensor definido por la operación `tf.add()` sin valor definido.
- C. Un tensor definido por la operación `tf.add()` con valor 5.

23. En el mismo código anterior, mul_op_2 (marca todas las respuestas correctas):

- A. No es utilizado en el resto del grafo y, por tanto, es incorrecto.
- B. No es evaluado como parte de `sess.run(pow_op)`.
- C. Sería evaluado junto con `mul_op` y `add_op` si hiciéramos `sess.run(mul_op_2)`.
- D. Sería evaluado junto con `add_op` si hiciéramos `sess.run(mul_op_2)`.

24. En el mismo código anterior, z (marca la respuesta correcta):

- A. Es un entero y tiene valor 15625.
- B. Es un objeto de tipo `tf.Session`.
- C. Es un objeto de tipo `tf.Session.run()`.
- D. Es un objeto de tipo `tf.Tensor`.

25. Selecciona todas las sentencias verdaderas sobre grafos de computación estáticos y dinámicos:

- A. Un grafo de computación estático necesita ser definido antes de evaluarlo con datos.
- B. Tanto los grafos de computación estáticos como dinámicos pueden ser evaluados mientras se definen.
- C. Los grafos de computación dinámicos permiten la utilización de sentencias de control como IF/ELSE de manera sencilla, ya que las instrucciones son evaluadas al momento.
- D. Los grafos de computación estáticos permiten la utilización de sentencias de control como IF/ELSE de manera sencilla, ya que las instrucciones son evaluadas al momento.

26. TensorFlow (marca todas las respuestas correctas):

- A. Es un framework de alto nivel y por tanto es complicado definir nuevos conceptos matemáticos y numéricos.
- B. Tiene una interfaz en Python, pero los cálculos numéricos se hacen en C++.
- C. Utiliza C++ para los cálculos numéricos en vez de Python por su mayor velocidad de cómputo.
- D. Utiliza Python para los cálculos numéricos porque es un lenguaje muy utilizado por la comunidad.
- E. Se utiliza solo para deep learning.

27. Marcar todos los frameworks que utilizan grafos de computación:

- A. TensorFlow.
- B. TensorFlow en su variante Eager Execution.
- C. PyTorch.
- D. Theano.

28. Marca todas las respuestas correctas acerca de Keras:

- A. Es utilizado normalmente en investigación para definir novedosas arquitecturas de bajo nivel.
- B. Es una librería derivada de TensorFlow.
- C. Es una librería de alto nivel que define una interfaz limpia y sencilla para el entrenamiento de redes neuronales.

29. ¿Cómo afecta al grafo de computación la definición de un optimizador en TensorFlow? (marca la respuesta correcta):

- A. No afecta al grafo, ya que el cálculo de gradientes no es una operación y no es necesario actualizar ningún tensor.
- B. Al definir el optimizador como parte del modelo, TensorFlow calcula las operaciones de gradientes necesarias a partir del grafo actual y las añade a este, de modo que es posible evaluar los gradientes y aplicar gradient descent durante la ejecución.
- C. No afecta al grafo. Los gradientes son computados de manera automática mediante mecanismos ajenos al grafo de computación.

30. En un modelo secuencial con Keras (marca la respuesta correcta):

- A. Las distintas capas se van añadiendo una detrás de otra y el modelo se compila con un optimizador.
- B. Las distintas capas se añaden al estilo de un grafo de computación y el modelo se compila con un optimizador.
- C. No existe el concepto de modelo secuencial en Keras.

31. Marca todas las respuestas correctas acerca de la inicialización de parámetros en una red neuronal:

- A. La inicialización de biases no es muy crítica una vez se ha definido una correcta inicialización de weights.
- B. La inicialización de parámetros no es importante, cualquier conjunto de valores iniciales permitirá

a la red converger correctamente.

C. No es buena idea inicializar todos los pesos con el mismo valor.

D. No es buena idea inicializar todos los biases con el mismo valor.

32. Si inicializamos todos los pesos w con valores muy grandes en valor absoluto (marca la respuesta correcta):

A. El uso de unidades sigmoid y tanh no sería una buena idea, ya que se encontrarán casi todo el tiempo en régimen de saturación.

B. En general no es un problema y es normal hacer esto al entrenar redes neuronales.

C. El entrenamiento de la red irá más rápido ya que los gradientes tendrán un valor mayor.

33. Batch normalization (marca todas las respuestas correctas):

A. Es una técnica que mejora el entrenamiento de redes neuronales.

B. Mejora los problemas que la inicialización de parámetros crea sobre las redes neuronales profundas.

C. Obtiene medias y varianzas a nivel de batch.

D. Funciona de manera distinta en training time (entrenamiento) que en test time (inferencia), ya que en el segundo podríamos querer evaluar inputs independientes sin formar parte de una batch.

34. Marca todas las respuestas correctas sobre SGD + Momentum:

A. SGD + Momentum es diferente a SGD porque no actúa por batches, sino utilizando todos los datos de entrenamiento por cada update.

B. El vector velocidad con Momentum ayuda a escapar de mínimos locales y puntos de silla.

C. El vector velocidad contiene información sobre los gradientes de todos los pasos anteriores.

D. $\text{Rho} = 0$ en el vector de velocidad hace que SGD + Momentum sea idéntico a SGD.

35. En AdaGrad, los gradientes al cuadrado de los parámetros (marca la respuesta correcta):

A. Se calculan de nuevo en cada paso y, una vez usados, son desechados.

B. Han de ser guardados, ya que el valor en cada iteración depende del valor anterior. Por tanto, el número de elementos a guardar se duplica (por un lado parámetros, por otro lado suma de gradientes).

C. No han de ser guardados, se recalcula toda la suma desde el principio en cada iteración.

36. Marca todas las respuestas correctas acerca de learning rate:

A. Una learning rate demasiado grande hace que el coste o loss diverja.

B. En learning rate decay, la learning rate va aumentando poco a poco para agilizar el entrenamiento.

C. AdaGrad, RMSProp y Adam utilizan learning rate como hiperparámetro.

D. Es más seguro utilizar un valor pequeño para asegurar la convergencia. Sin embargo, esto podría hacer que el entrenamiento sea demasiado lento.

37. ¿Cuál de las siguientes es una razón por la que las unidades ReLU tienen menos tendencia a «morir» cuando se aplican learning rates pequeñas?

A. Los learning rates grandes suelen estar asociados con valores de input negativos. En el caso de la ReLU, esto nos lleva a caer en el régimen negativo con valor de salida 0.

B. El régimen positivo de la unidad ReLU se caracteriza por tener derivada 1. Esto hace que los gradientes «backpropagados» se magnifiquen con valores grandes de learning rate, llevando a la unidad a la «muerte».

C. Un valor de learning rate grande lleva a cambios mayores en los parámetros de la red. Esto

implica que los pesos pueden cambiar mucho durante SGD e impedir que la unidad ReLU pueda volver a salir de su régimen negativo.

38. Marca todas las respuestas correctas acerca del overfitting:

- A. Es un problema por el cual los algoritmos de machine learning no se comportan correctamente en datos no vistos durante el entrenamiento.
- B. Es un problema por el que los algoritmos de machine learning pierden capacidad de generalización: no son capaces de generalizar a datos no vistos durante el entrenamiento.
- C. Puede ser combatido utilizando varias técnicas a la vez, tales como dropout y regularización L2.
- D. No es común en redes neuronales profundas.

39. ¿Qué ocurre con los gradientes en las neuronas desactivadas por dropout? (Marca la respuesta correcta):

- A. El proceso de backpropagation es el mismo, anular la salida no implica cambios en la propagación del gradiente.
- B. Los gradientes transmitidos hacia atrás multiplican por p la probabilidad de que la neurona se desactive.
- C. Los gradientes transmitidos hacia atrás son 0 en estas neuronas, ya que la función de salida de la neurona es constante y vale 0.

40. Early Stopping (marca las respuestas correctas):

- A. No impone explícitamente restricciones a la capacidad de representación del modelo. Simplemente marca un punto donde se deja de entrenar.
- B. Puede utilizarse en conjunción con otras técnicas.
- C. Garantiza que el test error es menor o igual que el training error.

41. Clasificar imágenes mediante el uso de redes neuronales convencionales con fully connected layers (marca la respuesta correcta):

- A. Se vuelve complicado computacionalmente al aumentar el tamaño de las imágenes.
- B. No es buena idea porque no respetamos las características espaciales de las imágenes.
- C. Es algo bastante común. Muchos problemas de computer vision se solucionan con fully connected neural networks.
- D. Es común entrelazar fully connected layers con convolutional layers.

42. Las CNN (marca todas las respuestas correctas):

- A. Empezaron a tener una gran importancia a partir de 1998.
- B. Se han convertido en una tecnología clave en problemas de visión por computador.
- C. Son utilizadas en self-driving cars para problemas como detectar peatones y otros coches a través de cámaras.
- D. Empezaron a tener una gran importancia en la década de 2010.

43. Cuando movemos un filtro por la imagen aplicando convoluciones (marca la respuesta correcta):

- A. Los parámetros del filtro son parámetros distintos en cada posición de la imagen sobre la que se aplica.
- B. Los parámetros del filtro son parámetros distintos en ciertas posiciones de la imagen detectadas por la red.

neuronal.

C. Los parámetros de un filtro son siempre los mismos para toda la imagen.

44. Las max pooling layers (marca la respuesta correcta):

A. Tienen dos parámetros y dos hiperparámetros.

B. Tienen dos hiperparámetros y no tienen parámetros.

C. No tienen parámetros ni hiperparámetros.

D. Tienen dos hiperparámetros y el número de parámetros de la capa depende del tamaño de la imagen.

45. Durante backpropagation, en la max pooling layer (marca la respuesta correcta):

A. El gradiente no se propaga hacia atrás ya que no hay parámetros.

B. El gradiente no se propaga hacia atrás ya que max pooling solo reduce dimensionalidad.

C. El gradiente se propaga de igual manera para todas las inputs.

D. El gradiente se propaga solo al valor de entrada que tenía el máximo valor durante el forward pass.

46. El volumen resultante de aplicar max pooling con pools de 2x2 y stride 2 sobre un volumen de tamaño 24x24x24 es (marca la respuesta correcta):

A. 12x12x24.

B. 12x12x12.

C. 24x24x12.

D. 24x24x24.

E. 24x12x12.

F. 12x24x12.

47. El volumen resultante de aplicar una capa convolucional con 16 filtros de tamaño 2x2 y stride 1 sobre un volumen de tamaño 5x5x4 es (marca la respuesta correcta):

A. 5x5x4.

B. 3x3x16.

C. 4x4x16.

D. 3x3x4.

E. 4x4x4.

F. Ninguna de las anteriores.

48. El volumen resultante de aplicar una capa convolucional con 16 filtros de tamaño 2x2 y stride 2 sobre un volumen de tamaño 5x5x4 es (marca la respuesta correcta):

A. 2,5x2,5x16.

B. 3x3x16.

C. 4x4x16.

D. 3x3x4.

E. 4x4x4.

F. Ninguna de las anteriores, las dimensiones no tienen sentido.

49. ¿Cuál de las siguientes son transformaciones válidas para data augmentation? (Marca todas las respuestas correctas):

- A. Rotar la imagen.
- B. Obtener el recorte de una parte de la imagen. Por ejemplo: en una imagen con un gato, obtener la cara del gato.
- C. Pasar una imagen a blanco y negro.
- D. Utilizar un objeto similar en la misma pose. Por ejemplo, en una imagen de un gato, cambiar al gato por un perro en el mismo sitio.
- E. Colorear la imagen con nuevos colores aleatorios.

50. Transfer learning (marca todas las respuestas correctas):

- A. Es apropiado cuando no disponemos de suficientes datos y tenemos un problema similar al de datasets como ImageNet.
- B. Permite entrenar CNN complejas con relativamente pocos datos.
- C. Aprovecha las representaciones obtenidas en otro problema rico en datos.

51. Una base de datos de palabras del estilo de WordNet (marca todas las respuestas correctas):

- A. Está construida por humanos.
- B. Permite obtener sinónimos y antónimos de palabras mediante grupos y reglas definidos por humanos.
- C. Contiene word vectors.

52. Bag-of-words (marca todas las respuestas correctas):

- A. Proporciona una representación discreta del texto.
- B. Asigna 0 a los elementos no presentes del vocabulario en el vector resultante.
- C. Asigna 1 a los elementos no presentes del vocabulario en el vector resultante.

53. Un word vector (marca la respuesta correcta):

- A. Es una representación discreta de una palabra.
- B. No permite obtener similitudes con otros word vectors.
- C. Es una representación distribuida de una palabra.

54. Los word vectors también se conocen como (marca la respuesta correcta):

- A. Word embeddings.
- B. Word discrete vectors.
- C. Discrete representations.
- D. Word contexts.

55. El tamaño de window o contexto m (marca la respuesta correcta):

- A. Es un parámetro del modelo word2vec y se aprende durante el entrenamiento.
- B. Es un hiperparámetro del modelo word2vec y se elige antes de entrenar el modelo.
- C. Un valor lógico para este parámetro sería $m = T$.
- D. Un valor lógico para este parámetro sería $m = 0$.

56. La dimensión d de los word vectors (marca la respuesta correcta):

- A. Es un parámetro del modelo word2vec y se aprende durante el entrenamiento.
- B. Es un hiperparámetro del modelo word2vec y se elige antes de entrenar el modelo.
- C. No es un parámetro ni un hiperparámetro y su valor no reviste importancia.

57. La similitud mediante cosenos (marca todas las respuestas correctas):

- A. Se basa en el ángulo entre dos vectores.
- B. Varía entre -1 y 1, con 1 siendo la máxima similitud y -1, la mínima.
- C. Varía entre 0 y 1, con 1 siendo la máxima similitud y 0 la mínima.
- D. Se obtiene a partir de un producto escalar normalizado mediante el módulo de los vectores.

58. Word2vec utiliza como datos (marca la respuesta correcta):

- A. Una representación discreta de un conjunto de textos.
- B. Un conjunto de textos.
- C. Un conjunto de textos, pero necesitamos a humanos que asignen a cada texto una clase correcta, como en un problema de clasificación.
- D. Word2vec no necesita datos.

59. Los word vectors resultantes de word2vec (marca la respuesta correcta):

- A. Codifican una representación de las palabras con ciertos valores semánticos, de manera que pueden calcularse palabras similares a otras y detectar relaciones entre ellas.
- B. Codifican una representación de las palabras con valores puramente estructurales, de manera que solo podemos saber palabras que se suelen comportar como sustantivos, verbos, adverbios, etc.
- C. Codifican una representación discreta de las palabras.
- D. Ninguna de las anteriores.

60. Negative sampling (marca la respuesta correcta):

- A. Es una técnica que no se usa en la práctica, ya que basta con aplicar gradient descent sobre el problema completo de word2vec.
- B. Consiste en utilizar solo una pequeña parte aleatoria de los textos de los que disponemos.
- C. Es una aproximación al problema de optimización completo de word2vec que resulta mucho más eficiente computacionalmente.
- D. Ninguna de las anteriores.

61. Las RNN se diferencian de las redes neuronales tradicionales en que (marca todas las respuestas correctas):

- A. Pueden trabajar sobre una secuencia de inputs de manera natural.
- B. Pueden producir una secuencia de outputs de manera natural.
- C. Tienen un estado interno que permite guardar información sobre lo que la red ha visto hasta ahora.

62. En un problema de traducción automática (marca la respuesta correcta):

- A. Tenemos un solo input y producimos una secuencia.
- B. Tenemos una secuencia de entrada y producimos una sola salida.
- C. Tenemos una secuencia de entrada y producimos una secuencia de salida.
- D. Ninguna de las anteriores.

63. En una vanilla RNN, los parámetros a aprender en la red son (marca la respuesta correcta):

- A. Las matrices W_{hh} , W_{xh} y W_{hy} .
- B. Las matrices W_{hh} y W_{xh} .
- C. Los estados internos h_t para cada t .
- D. Los valores de las input x_t .
- E. Ninguna de las anteriores.

64. El vector de hidden state h_t (marca la respuesta correcta):

- A. Almacena todas las inputs que la red ha visto hasta el momento.
- B. A menor tamaño, más capacidad de memorizar el pasado.
- C. A mayor tamaño, la red neuronal entrenará o se ejecutará más rápido.
- D. Es una representación interna en forma de vector que codifica los estados por los que la red ha pasado y las inputs que ha ido viendo en el tiempo.

65. Marca todas las respuestas correctas acerca de backpropagation through time:

- A. Es el equivalente al algoritmo de backpropagation aplicado a RNN.
- B. En el forward pass calculamos todas las salidas a lo largo del tiempo.
- C. A veces las secuencias pueden ser muy largas (por ejemplo, un texto completo para entrenar un modelo del lenguaje), por lo que se recurre a truncated backpropagation through time.

66. ¿Cuál es una diferencia entre los modelos del lenguaje tradicionales vistos en clase y un modelo del lenguaje con RNN? (Marca la respuesta correcta):

- A. En un modelo del lenguaje con RNN no modelamos probabilidades.
- B. En un modelo del lenguaje con RNN el hidden state es la probabilidad de una palabra dadas todas las anteriores, no hace falta contar las ocurrencias de palabras.
- C. Los modelos tradicionales utilizan redes neuronales no recurrentes.
- D. Un modelo del lenguaje con RNN no necesita modelar probabilidades con cuentas, se utiliza un modelo de predicción en el que el estado interno de la red codifica la información necesaria para obtener las probabilidades buscadas.

67. ¿Qué ventajas puede tener utilizar word vectors en vez de representaciones one-hot como entrada en una red recurrente? (Marca todas las respuestas correctas):

- A. Ninguna, ambas son equivalentes.
- B. Con una representación one-hot no podemos distinguir entre palabras distintas.
- C. Los word vectors contienen información semántica de la palabra que una red neuronal puede utilizar para modelar mejor el problema a resolver.
- D. Si el vocabulario es muy grande, una representación discreta como la one-hot da lugar a vectores de entrada muy grandes, mientras que una representación densa como los word vectors permite un vector más compacto.

68. Gradient clipping (marca la respuesta correcta):

- A. Controla la magnitud del gradiente durante backpropagation. Si este se hace muy grande, se reduce su magnitud para evitar el problema de exploding gradients.
- B. Controla la magnitud del gradiente durante backpropagation. Si este se hace muy pequeño, se incrementa su magnitud para evitar el problema de vanishing gradients.
- C. Controla la magnitud del gradiente durante el forward pass. Si este se hace muy grande, se reduce su magnitud para evitar el problema de exploding gradients.
- D. Controla la magnitud del gradiente durante el forward pass. Si este se hace muy pequeño, se reduce su magnitud para evitar el problema de vanishing gradients.

69. La arquitectura LSTM (marca las respuestas correctas):

- A. Surge como una arquitectura que trata de modelar con éxito relaciones temporales de larga distancia.
- B. La input gate (i) controla cuánto olvidamos del estado interno anterior.
- C. Utiliza tanto sigmoids como tanhs en sus representaciones internas.
- D. La forget gate (f) controla cuánta información fluye hacia el hidden state.
- E. Soluciona el problema de los vanishing gradients.

70. Al apilar RNN (marca la respuesta correcta):

- A. La salida del último time step de una RNN se pasa como primer input a la siguiente RNN.
- B. Solo la salida del primer time step de una RNN se pasa como input a la siguiente RNN.
- C. Las salidas de cada time step de la primera RNN son las entradas de la siguiente RNN.
- D. Ninguna de las anteriores.

71. En reinforcement learning (marca la respuesta correcta):

- A. Un agente está en un entorno y trata de aprender recompensas a partir del estado en el que se encuentra.
- B. Un agente está en un entorno y trata de aprender los estados óptimos del entorno.
- C. Un agente está en un entorno y trata de aprender las acciones que maximizan las recompensas en cada estado posible.
- D. Un agente está en un entorno y trata de aprender las acciones que minimizan las recompensas en cada estado posible.

72. ¿Cuál de los siguientes problemas está definido como un problema de reinforcement learning? (marca todas las respuestas correctas):

- A. Un helicóptero autónomo puede realizar acciones como mover las aspas y cambiar la dirección. Recibe rewards positivas si se mantiene en vuelo y negativas si cae al suelo.
- B. Un robot industrial tiene que mover objetos de un sitio a otro y sus acciones son el movimiento de una mano mecánica. Recibe rewards positivas por mover el objeto con éxito.
- C. Un clasificador de imágenes tiene una serie de imágenes y unas etiquetas por cada imagen. El clasificador aprende a catalogar las imágenes según las etiquetas.
- D. Un algoritmo de recomendación asigna a cada usuario los vídeos más probables a ver en el futuro según el historial del usuario.

73. El entorno o environment en un problema de reinforcement learning nos da (marca todas las respuestas correctas):

- A. Una acción a_t a realizar para el agente.
- B. Una recompensa r_t a partir del estado y la acción realizada por el agente.
- C. Un nuevo estado s_{t+1} a partir del estado s_t y la acción a_t realizada por el agente.
- D. Una policy a seguir por el agente.

74. La value function V (marca todas las respuestas correctas):

- A. Está asociada a una policy π y la trayectoria que definen las acciones de esta policy.
- B. Si el discount factor es 1, todas las recompensas valen lo mismo independientemente de en qué momento del tiempo se consiguen.

C. Nos da una medida de lo bueno que es un estado siguiendo una policy π a partir de las recompensas esperadas si seguimos la policy desde ese estado.

D. Nos da una medida de lo bueno que es un estado y una acción siguiendo una policy π a partir de las recompensas esperadas si seguimos la policy desde ese estado.

75. A partir de Q , podemos obtener la optimal policy π (marca la respuesta correcta):**

A. Por cada estado s , elegimos la acción que nos da un valor mayor de $Q^*(s,a)$.

B. Por cada estado s , aplicamos la ecuación de Bellman a partir de Q^* para obtener el nuevo estado s' y acción a' .

C. Es imposible calcular π^* a partir de Q^* .

76. Q-learning a partir de value iteration (marca la respuesta correcta):

A. Se caracteriza por no utilizar la ecuación de Bellman.

B. Se hace computacionalmente intratable cuando hay muchos estados o acciones.

C. Converge mejor a mayor número de acciones.

77. En el algoritmo Deep Q-Learning visto en clase, la red neuronal tiene una salida por cada acción, en vez de representar la acción como input. Esto es así porque (marca la respuesta correcta):

A. El número de acciones puede llegar a ser muy grande.

B. El número de estados puede llegar a ser muy grande.

C. Podemos obtener todos los Q-values para un estado con un solo forward pass.

D. Ninguna de las anteriores.

78. Experience Replay (marca todas las respuestas correctas):

A. Define una memoria de jugadas guardadas con sus rewards de manera que podemos obtener jugadas aleatorias a partir de ella.

B. Es una memoria que guarda jugadas, v-values y q-values para cada jugada.

C. Hace el entrenamiento más eficiente al mostrar jugadas variadas en vez de jugadas consecutivas.

79. En el algoritmo Deep Q-Learning es importante dar cierta probabilidad a realizar acciones aleatorias porque (marca todas las respuestas correctas):

A. En un principio, la red neuronal es aleatoria y no puede ser considerada como una policy óptima.

B. Es importante explorar nuevas acciones para descubrir sus recompensas y no quedar atrapado en políticas subóptimas.

C. Incluso cuando la red defina una buena aproximación a Q^* , es importante probar nuevas acciones que puedan llevar a mejores soluciones.

80. El estado en Deep Q-Learning aplicado a videojuegos Atari es (marca la respuesta correcta):

A. Una serie de valores simbólicos y formales que definen el estado del juego.

B. Un sistema de ecuaciones que define velocidad de la bola, la física respecto a la paleta, etc.

C. Las imágenes del juego que ve un jugador (dispuestas en conjuntos de 4 frames seguidos).

D. Ninguna de las anteriores.

81. Las GPU (marca todas las respuestas correctas):

- A. Están optimizadas para realizar operaciones gráficas, por eso son utilizadas solo con CNN.
- B. Están optimizadas para realizar ciertas operaciones con números de coma flotante. Estas operaciones pueden ser utilizadas tanto para gráficos como para computación numérica.
- C. Han permitido disminuir el tiempo de entrenamiento de las redes profundas en gran medida.

82. ¿Cuáles son las diferencias entre una CPU y una GPU? (Marca todas las respuestas correctas):

- A. Las GPU tienen un número mucho mayor de cores.
- B. Las GPU son un tipo especial de memoria inteligente, no tienen procesador.
- C. Las GPU tienen memoria RAM propia, mientras que las CPU utilizan la memoria del sistema.
- D. Las GPU utilizan la memoria RAM del sistema, mientras que las CPU tienen una memoria propia e independiente.
- E. Las GPU están optimizadas para grandes anchos de banda de memoria, mientras que las CPU lo están para conseguir latencias bajas al leer de memoria.

83. ¿Qué elementos se necesitan guardar en la memoria de una GPU? (marca la respuesta correcta):

- A. Todos los datos de entrenamiento.
- B. Todos los datos de test.
- C. Los parámetros del modelo.

84. En una multiplicación de matrices con GPU (marca la respuesta correcta):

- A. La GPU lee las matrices a multiplicar de memoria y utiliza sus múltiples cores para obtener los valores resultantes de manera paralela, calculando en cada core un producto escalar.
- B. La CPU y la GPU se coordinan, leen las matrices a multiplicar de memoria y suman sus cores para obtener los valores resultantes de manera paralela, calculando en cada core un producto escalar.
- C. Ninguna de las anteriores.

85. cuDNN (marca todas las respuestas correctas):

- A. Es una librería C genérica para operaciones en paralelo en GPU.
- B. Define primitivas de operaciones comunes en deep learning.
- C. Paraleliza de manera eficiente en código CUDA operaciones como convoluciones y RNN.
- D. Es una librería de código abierto válido en todo tipo de arquitecturas.
- E. Es utilizada por frameworks como TensorFlow, Caffe2 y MXnet.

86. En un sistema distribuido, la velocidad de la red de comunicaciones (marca la respuesta correcta):

- A. Es importante solo para leer los datos de entrenamiento de manera rápida, que no suelen caber en una sola máquina y se encuentran a su vez distribuidos en un sistema tipo HDFS.
- B. Es importante solo para mover los parámetros del modelo entre máquinas de manera rápida.
- C. Es fundamental tanto para leer los datos de entrenamiento como para mover los parámetros del modelo entre máquinas.
- D. No es tan importante como el conseguir el mayor número posible de máquinas.

87. Entrenar en un sistema distribuido (marca la respuesta correcta):

- A. Debería hacerse siempre que sea posible para optimizar el entrenamiento.
- B. Si utilizamos 20 máquinas, entrenaremos 20 veces más rápido.
- C. Se ha de recurrir a ello de manera lógica cuando la escala de nuestros datos y modelos nos lleva a tiempos demasiados largos de entrenamiento para nuestra aplicación particular.
- D. Ninguna de las anteriores.

88. El modelo CNN de AlexNet fue originalmente entrenado usando (marca la respuesta correcta):

- A. Data parallelism.
- B. Model parallelism.
- C. Ambos, data y model parallelism.
- D. Ningún tipo de paralelización.

89. En parameter averaging (marca la respuesta correcta):

- A. No es necesario esperar a todos los workers para actualizar el modelo.
- B. No es necesario tener un parameter server.
- C. Cada worker tiene una copia completa del modelo.
- D. Una vez se ha hecho la media de parámetros, cada worker recibe unos parámetros de vuelta distintos.

90. En Downpour SGD (marca todas las respuestas correctas):

- A. No es necesario esperar a todos los workers para actualizar el modelo.
- B. No es necesario tener un parameter server.
- C. Cada worker tiene una copia completa del modelo.
- D. Cada worker recibe unos parámetros de vuelta distintos al entregar sus updates.

61. Las RNN se diferencian de las redes neuronales tradicionales en que (marca todas las respuestas correctas):

- A. Pueden trabajar sobre una secuencia de inputs de manera natural.
- B. Pueden producir una secuencia de outputs de manera natural.
- C. Tienen un estado interno que permite guardar información sobre lo que la red ha visto hasta ahora.

62. En un problema de traducción automática (marca la respuesta correcta):

- A. Tenemos un solo input y producimos una secuencia.
- B. Tenemos una secuencia de entrada y producimos una sola salida.
- C. Tenemos una secuencia de entrada y producimos una secuencia de salida.
- D. Ninguna de las anteriores.

63. En una vanilla RNN, los parámetros a aprender en la red son (marca la respuesta correcta):

- A. Las matrices W_{hh} , W_{xh} y W_{hy} .
- B. Las matrices W_{hh} y W_{xh} .
- C. Los estados internos h_t para cada t .
- D. Los valores de las input x_t .
- E. Ninguna de las anteriores.

64. El vector de hidden state h_t (marca la respuesta correcta):

- A. Almacena todas las inputs que la red ha visto hasta el momento.
- B. A menor tamaño, más capacidad de memorizar el pasado.
- C. A mayor tamaño, la red neuronal entrenará o se ejecutará más rápido.
- D. Es una representación interna en forma de vector que codifica los estados por los que la red ha pasado y las inputs que ha ido viendo en el tiempo.

65. Marca todas las respuestas correctas acerca de backpropagation through time:

- A. Es el equivalente al algoritmo de backpropagation aplicado a RNN.
- B. En el forward pass calculamos todas las salidas a lo largo del tiempo.

C. A veces las secuencias pueden ser muy largas (por ejemplo, un texto completo para entrenar un modelo del lenguaje), por lo que se recurre a truncated backpropagation through time.

66. ¿Cuál es una diferencia entre los modelos del lenguaje tradicionales vistos en clase y un modelo del lenguaje con RNN? (Marca la respuesta correcta):

- A. En un modelo del lenguaje con RNN no modelamos probabilidades.
- B. En un modelo del lenguaje con RNN el hidden state es la probabilidad de una palabra dadas todas las anteriores, no hace falta contar las ocurrencias de palabras.
- C. Los modelos tradicionales utilizan redes neuronales no recurrentes.
- D. Un modelo del lenguaje con RNN no necesita modelar probabilidades con cuentas, se utiliza un modelo de predicción en el que el estado interno de la red codifica la información necesaria para obtener las probabilidades buscadas.

67. ¿Qué ventajas puede tener utilizar word vectors en vez de representaciones one-hot como entrada en una red recurrente? (Marca todas las respuestas correctas):

- A. Ninguna, ambas son equivalentes.
- B. Con una representación one-hot no podemos distinguir entre palabras distintas.
- C. Los word vectors contienen información semántica de la palabra que una red neuronal puede utilizar para modelar mejor el problema a resolver.
- D. Si el vocabulario es muy grande, una representación discreta como la one-hot da lugar a vectores de entrada muy grandes, mientras que una representación densa como los word vectors permite un vector más compacto.

68. Gradient clipping (marca la respuesta correcta):

- A. Controla la magnitud del gradiente durante backpropagation. Si este se hace muy grande, se reduce su magnitud para evitar el problema de exploding gradients.
- B. Controla la magnitud del gradiente durante backpropagation. Si este se hace muy pequeño, se incrementa su magnitud para evitar el problema de vanishing gradients.
- C. Controla la magnitud del gradiente durante el forward pass. Si este se hace muy grande, se reduce su magnitud para evitar el problema de exploding gradients.
- D. Controla la magnitud del gradiente durante el forward pass. Si este se hace muy pequeño, se reduce su magnitud para evitar el problema de vanishing gradients.

69. La arquitectura LSTM (marca las respuestas correctas):

- A. Surge como una arquitectura que trata de modelar con éxito relaciones temporales de larga distancia.
- B. La input gate (i) controla cuánto olvidamos del estado interno anterior.
- C. Utiliza tanto sigmoids como tanhs en sus representaciones internas.
- D. La forget gate (f) controla cuánta información fluye hacia el hidden state.
- E. Soluciona el problema de los vanishing gradients.

70. Al apilar RNN (marca la respuesta correcta):

- A. La salida del último time step de una RNN se pasa como primer input a la siguiente RNN.
- B. Solo la salida del primer time step de una RNN se pasa como input a la siguiente RNN.
- C. Las salidas de cada time step de la primera RNN son las entradas de la siguiente RNN.
- D. Ninguna de las anteriores.

En reinforcement learning (marca la respuesta correcta):
Pregunta 1 Seleccione una:
A. Un agente está en un entorno y trata de aprender recompensas a partir del estado en el que se encuentra.
B. Un agente está en un entorno y trata de aprender los estados óptimos del entorno.
C. Un ag

pasted

71. En reinforcement learning (marca la respuesta correcta):

- A. Un agente está en un entorno y trata de aprender recompensas a partir del estado en el que se encuentra.
- B. Un agente está en un entorno y trata de aprender los estados óptimos del entorno.
- C. Un agente está en un entorno y trata de aprender las acciones que maximizan las recompensas en cada estado posible.
- D. Un agente está en un entorno y trata de aprender las acciones que minimizan las recompensas en cada estado posible.

72. ¿Cuál de los siguientes problemas está definido como un problema de reinforcement learning? (marca todas las respuestas correctas):

- A. Un helicóptero autónomo puede realizar acciones como mover las aspas y cambiar la dirección. Recibe rewards positivas si se mantiene en vuelo y negativas si cae al suelo.
- B. Un robot industrial tiene que mover objetos de un sitio a otro y sus acciones son el movimiento de una mano mecánica. Recibe rewards positivas por mover el objeto con éxito.
- C. Un clasificador de imágenes tiene una serie de imágenes y unas etiquetas por cada imagen. El clasificador aprende a catalogar las imágenes según las etiquetas.
- D. Un algoritmo de recomendación asigna a cada usuario los vídeos más probables a ver en el futuro según el historial del usuario.

73. El entorno o environment en un problema de reinforcement learning nos da (marca todas las respuestas correctas):

- A. Una acción a_t a realizar para el agente.
- B. Una recompensa r_t a partir del estado y la acción realizada por el agente.
- C. Un nuevo estado s_{t+1} a partir del estado s_t y la acción a_t realizada por el agente.
- D. Una policy a seguir por el agente.

74. La value function V (marca todas las respuestas correctas):

- A. Está asociada a una policy π y la trayectoria que definen las acciones de esta policy.
- B. Si el discount factor es 1, todas las recompensas valen lo mismo independientemente de en qué momento del tiempo se consiguen.
- C. Nos da una medida de lo bueno que es un estado siguiendo una policy π a partir de las recompensas esperadas si seguimos la policy desde ese estado.
- D. Nos da una medida de lo bueno que es un estado y una acción siguiendo una policy π a partir de las recompensas esperadas si seguimos la policy desde ese estado.

75. A partir de Q , podemos obtener la optimal policy π (marca la respuesta correcta):**

- A. Por cada estado s , elegimos la acción que nos da un valor mayor de $Q^*(s,a)$.
- B. Por cada estado s , aplicamos la ecuación de Bellman a partir de Q^* para obtener el nuevo estado s' y acción a' .
- C. Es imposible calcular π^* a partir de Q^* .

76. Q-learning a partir de value iteration (marca la respuesta correcta):

- A. Se caracteriza por no utilizar la ecuación de Bellman.
- B. Se hace computacionalmente intratable cuando hay muchos estados o acciones.
- C. Converge mejor a mayor número de acciones.

77. En el algoritmo Deep Q-Learning visto en clase, la red neuronal tiene una salida por cada acción, en vez de representar la acción como input. Esto es así porque (marca la respuesta correcta):

- A. El número de acciones puede llegar a ser muy grande.
- B. El número de estados puede llegar a ser muy grande.
- C. Podemos obtener todos los Q-values para un estado con un solo forward pass.
- D. Ninguna de las anteriores.

78. Experience Replay (marca todas las respuestas correctas):

- A. Define una memoria de jugadas guardadas con sus rewards de manera que podemos obtener jugadas aleatorias a partir de ella.
- B. Es una memoria que guarda jugadas, v-values y q-values para cada jugada.
- C. Hace el entrenamiento más eficiente al mostrar jugadas variadas en vez de jugadas consecutivas.

79. En el algoritmo Deep Q-Learning es importante dar cierta probabilidad a realizar acciones aleatorias porque (marca todas las respuestas correctas):

- A. En un principio, la red neuronal es aleatoria y no puede ser considerada como una policy óptima.
- B. Es importante explorar nuevas acciones para descubrir sus recompensas y no quedar atrapado en políticas subóptimas.
- C. Incluso cuando la red defina una buena aproximación a Q^* , es importante probar nuevas acciones que puedan llevar a mejores soluciones.

80. El estado en Deep Q-Learning aplicado a videojuegos Atari es (marca la respuesta correcta):

- A. Una serie de valores simbólicos y formales que definen el estado del juego.
- B. Un sistema de ecuaciones que define velocidad de la bola, la física respecto a la paleta, etc.
- C. Las imágenes del juego que ve un jugador (dispuestas en conjuntos de 4 frames seguidos).
- D. Ninguna de las anteriores.

Las GPU (marca todas las respuestas correctas): Pregunta 1 Seleccione una o más de una: A. Están optimizadas para realizar operaciones gráficas, por eso son utilizadas solo con CNN. B. Están optimizadas para realizar ciertas operaciones con números de coma flotante. Estas operaciones puede

pasted

81. Las GPU (marca todas las respuestas correctas):

- A. Están optimizadas para realizar operaciones gráficas, por eso son utilizadas solo con CNN.
- B. Están optimizadas para realizar ciertas operaciones con números de coma flotante. Estas operaciones pueden ser utilizadas tanto para gráficos como para computación numérica.
- C. Han permitido disminuir el tiempo de entrenamiento de las redes profundas en gran medida.

82. ¿Cuáles son las diferencias entre una CPU y una GPU? (Marca todas las respuestas correctas):

- A. Las GPU tienen un número mucho mayor de cores.
- B. Las GPU son un tipo especial de memoria inteligente, no tienen procesador.
- C. Las GPU tienen memoria RAM propia, mientras que las CPU utilizan la memoria del sistema.
- D. Las GPU utilizan la memoria RAM del sistema, mientras que las CPU tienen una memoria propia e independiente.
- E. Las GPU están optimizadas para grandes anchos de banda de memoria, mientras que las CPU lo están para conseguir latencias bajas al leer de memoria.

83. ¿Qué elementos se necesitan guardar en la memoria de una GPU? (marca la respuesta correcta):

- A. Todos los datos de entrenamiento.
- B. Todos los datos de test.
- C. Los parámetros del modelo.

84. En una multiplicación de matrices con GPU (marca la respuesta correcta):

- A. La GPU lee las matrices a multiplicar de memoria y utiliza sus múltiples cores para obtener los valores resultantes de manera paralela, calculando en cada core un producto escalar.
- B. La CPU y la GPU se coordinan, leen las matrices a multiplicar de memoria y suman sus cores para obtener los valores resultantes de manera paralela, calculando en cada core un producto escalar.
- C. Ninguna de las anteriores.

85. cuDNN (marca todas las respuestas correctas):

- A. Es una librería C genérica para operaciones en paralelo en GPU.
- B. Define primitivas de operaciones comunes en deep learning.
- C. Paraleliza de manera eficiente en código CUDA operaciones como convoluciones y RNN.
- D. Es una librería de código abierto válido en todo tipo de arquitecturas.
- E. Es utilizada por frameworks como TensorFlow, Caffe2 y MXnet.

86. En un sistema distribuido, la velocidad de la red de comunicaciones (marca la respuesta correcta):

- A. Es importante solo para leer los datos de entrenamiento de manera rápida, que no suelen caber en una sola máquina y se encuentran a su vez distribuidos en un sistema tipo HDFS.
- B. Es importante solo para mover los parámetros del modelo entre máquinas de manera rápida.
- C. Es fundamental tanto para leer los datos de entrenamiento como para mover los parámetros del modelo entre máquinas.
- D. No es tan importante como el conseguir el mayor número posible de máquinas.

87. Entrenar en un sistema distribuido (marca la respuesta correcta):

- A. Debería hacerse siempre que sea posible para optimizar el entrenamiento.
- B. Si utilizamos 20 máquinas, entrenaremos 20 veces más rápido.
- C. Se ha de recurrir a ello de manera lógica cuando la escala de nuestros datos y modelos nos lleva a tiempos demasiados largos de entrenamiento para nuestra aplicación particular.
- D. Ninguna de las anteriores.

88. El modelo CNN de AlexNet fue originalmente entrenado usando (marca la respuesta correcta):

- A. Data paralellism.
- B. Model parallelism.
- C. Ambos, data y model parallelism.
- D. Ningún tipo de paralelización.

89. En parameter averaging (marca la respuesta correcta):

- A. No es necesario esperar a todos los workers para actualizar el modelo.
- B. No es necesario tener un parameter server.
- C. Cada worker tiene una copia completa del modelo.

D. Una vez se ha hecho la media de parámetros, cada worker recibe unos parámetros de vuelta distintos.

90. En Downpour SGD (marca todas las respuestas correctas):

- A. No es necesario esperar a todos los workers para actualizar el modelo.
- B. No es necesario tener un parameter server.
- C. Cada worker tiene una copia completa del modelo.
- D. Cada worker recibe unos parámetros de vuelta distintos al entregar sus updates.

Hacer batching en serving time es deseable porque (marca la respuesta correcta): Pregunta 1
Seleccione una: A. Permite ejecutar varias requests a la vez. B. Permite la utilización de varios servidores concurrentes para ejecutar una batch más rápido. C. En sistemas con un gran número de requests, el batching reduce el tiempo de respuesta.
pasted

91. Hacer batching en serving time es deseable porque (marca la respuesta correcta):

- A. Permite ejecutar varias requests a la vez.
- B. Permite la utilización de varios servidores concurrentes para ejecutar una batch más rápido.
- C. En sistemas con un gran número de requests por segundo permite combinar varias a la vez y calcular la salida más rápido que si se fuera una a una.

92. Durante el proceso de inferencia se realiza (marca la respuesta correcta):

- A. Solo el forward pass de una red.
- B. Solo el backward pass de una red.
- C. Ambos, forward y backward passes.
- D. Ninguno de ellos.

93. Un servidor con concurrencia (marca las respuestas correctas):

- A. Explora las capacidades multihilo de los procesadores y permite tratar varias requests a la vez.
- B. Permite reducir el tiempo de respuesta ante la presencia de solicitudes concurrentes.
- C. Permite aumentar el número total de requests por segundo que pueden ser respondidas.
- D. No aporta grandes ventajas si el servidor recibe una request cada minuto.

94. Un balanceador de carga (marca la respuesta correcta):

- A. Balancea el versionado de modelos en un conjunto de servidores distribuidos.
- B. Almacena requests y las envía en forma de batch a un servidor.
- C. Mejora el tiempo de respuesta mediante la aplicación de concurrencia en un servidor.
- D. Ninguna de las anteriores.

95. Un ecosistema en la nube tipo AWS o GCP (marca la respuesta correcta):

- A. Facilita el desarrollo de soluciones informáticas permitiendo que los desarrolladores no tengan que centrarse en el código.
- B. Facilita el desarrollo de soluciones informáticas, abstrayendo a los desarrolladores de la complejidad de instalar y mantener complejos sistemas de hardware.
- C. Suele ser más caro que instalar y mantener tu propio hardware.
- D. Es un servicio de hosting de páginas web.

96. Una API de inteligencia artificial de un proveedor en la nube (marca la respuesta correcta):

- A. Puede ser útil cuando necesitamos resolver un problema específico. Por ejemplo, queremos convertir audio a texto, para lo cual existen muchas soluciones disponibles.

- B. Es útil cuando tenemos una necesidad particular y compleja. Por ejemplo, queremos entrenar un modelo que clasifique imágenes de distintas series de televisión.
- C. Ninguna de las anteriores.

97. ¿Cuáles de los siguientes puntos pueden hacer la extracción de datos y features en un proceso complejo? (marca las respuestas correctas):

- A. Normalmente ninguno, la extracción de datos suele ser siempre la parte más sencilla a implementar.
- B. Los datos necesarios pueden provenir de varias fuentes distintas (bases de datos, logs...).
- C. Los datos en bruto pueden necesitar ser tratados para que sean útiles para nuestro modelo.
- D. Es posible que los datos no estén siendo almacenados hasta el momento, por lo que es necesario crear esa lógica.

98. ¿Cuáles de los siguientes casos puede dar lugar a training-serving skew? (marca las respuestas correctas):

- A. Entrenar un modelo de reconocimiento de caras solo con personas de pelo moreno y sin gafas.
- B. Olvidar que la feature «edad del usuario» no está disponible a la hora de servir, pero se ha usado para entrenar.
- C. Poner, sin querer, en producción un modelo con malas métricas de entrenamiento.
- D. Entrenar un modelo de recomendación solo con los usuarios que están suscritos al servicio.

99. Una continuous training pipeline (marca la respuesta correcta):

- A. Permite entrenar modelos de manera óptima a partir de cualquier fuente de datos.
- B. Es un conjunto de componentes que evitan el training-serving skew y otros problemas en machine learning.
- C. Es un sistema donde un modelo de machine learning es entrenado y puesto en producción de manera automática de forma periódica.

100. Una forma de evitar el problema del comportamiento inestable del modelo en subpoblaciones sería (marca la respuesta correcta):

- A. A la hora de evaluar el modelo entrenado, tener datos de test separados según las subpoblaciones que nos interesan más y comprobar las métricas del modelo en cada una de estas subpoblaciones.
- B. Asegurarnos de que el código que extrae los datos para el modelo es el mismo en training y serving time.
- C. Comprobar que las distribuciones de los datos a la hora de entrenar y servir son las mismas.

101. Con un modelo generativo (marca la respuesta correcta):

- A. Podemos generar nuevos ejemplos de datos a partir de lo aprendido con los datos de entrenamiento.
- B. Aprendemos la distribución de probabilidad de las labels «y» a partir de los datos «x», con lo cual podemos generar nuevos datos.
- C. Ninguna de las anteriores.

102. Las generative adversarial networks (marca la respuesta correcta):

- A. Modelan explícitamente una función de densidad.
- B. Modelan implícitamente una función de densidad.
- C. Tanto A como B son ciertas.
- D. Ni A ni B son ciertas.

103. Al entrenar una GAN (marca la respuesta correcta):

- A. Solo la generator network mejora con el tiempo. La discriminative network se mantiene constante y el proceso de entrenamiento termina cuando esta es engañada en la mayoría de ocasiones.
- B. Solo la discriminator network mejora con el tiempo. El entrenamiento termina cuando esta es capaz de distinguir entre resultados reales y falsos.
- C. Ambas, generator y discriminator network, mejoran con el tiempo. La generator aprende a obtener resultados más parecidos a los datos reales, mientras que la discriminator aprende a distinguir mejor, forzando a su vez a la otra red a mejorar con el tiempo.
- D. Ninguna de las anteriores.

104. El resultado de interés al entrenar una GAN es principalmente (marca la respuesta correcta):

- A. La generator network: es el modelo generativo resultante.
- B. La discriminator network: nos permite distinguir inputs falsos.
- C. La combinación de ambas: nos permite generar imágenes y luego comprobar si son suficientemente buenas.

105. La salida de $D(x)$ de la discriminator network (marca la respuesta correcta):

- A. Es una imagen u otro contenido a generar, según la aplicación.
- B. Es la probabilidad de que la imagen de entrada de la red sea verdadera o falsa.
- C. Es la probabilidad de que el generador haya generado una imagen real.
- D. Es la probabilidad de que el generador haya generado una imagen falsa.

106. En una generator network, podemos generar imágenes distintas (marca la respuesta correcta):

- A. Cambiando los valores del input. Distintos valores aleatorios de entrada arrojan distintas imágenes de salida.
- B. Suministrando una imagen distinta al input de la generator network.
- C. Ninguna de las anteriores.

107. Los sistemas actuales de inteligencia artificial (marca la respuesta correcta):

- A. Aprenden rápidamente cualquier tipo de tarea sin necesidad de una gran cantidad de datos y búsqueda de arquitecturas.
- B. Necesitan una gran cantidad de datos para aprender una tarea, pero luego son capaces de aprender tareas similares con una efectividad cercana a las de los humanos.
- C. Principalmente, son muy efectivos en tareas concretas para las que hemos encontrado buenos algoritmos y una buena fuente de datos.

108. ¿Cuáles de las siguientes son formas de aplicar meta-learning? (Marca las respuestas correctas):

- A. Aprender el optimizador a utilizar para una tarea.
- B. Realizar un hyperparameter tuning en nuestro modelo probando varios hiperparámetros distintos al azar.
- C. Aprender cómo generar arquitecturas de redes neuronales más efectivas para una tarea.
- D. Utilizar varios tipos de modelos distintos para ver cuál da mejores resultados en una tarea.

109. En AutoML (marca la respuesta correcta):

- A. Se intenta aprender un optimizador óptimo para un problema en concreto.
- B. Se intenta aprender una serie de hiperparámetros óptimos para un problema en concreto.
- C. Se intenta generar una red neuronal óptima para un problema en concreto.

110. En few-shot learning (marca la respuesta correcta):

- A. El objetivo es que un sistema de inteligencia artificial sea capaz de generalizar conceptos y aprender a partir de pocos ejemplos.
- B. Se intenta que una máquina aprenda sin ningún dato de entrenamiento.
- C. El objetivo es conseguir mejores arquitecturas de redes neuronales.